

Ablation de loss boundary pour la segmentation Cityscapes pleine résolution : quand le Dice aide, et quand il ne sert plus à rien

Guillaume Cassez

Recherche indépendante · ORCID 0009-0007-0987-3931 · cassez.guillaume@gmail.com · guillaume-cassez.fr

Cityscapes val · ConvNeXt-V2-Base + UPerNet · 4 variantes de loss × 3 seeds × 160 epochs à 1024×2048

Résumé

On rapporte une ablation contrôlée des fonctions de loss boundary-aware pour la segmentation sémantique à la résolution native Cityscapes (1024×2048). Avec un backbone ConvNeXt-V2-Base et une tête UPerNet, quatre configurations de loss sont entraînées pendant 160 epochs sur trois seeds aléatoires chacune, soit douze runs au total, évaluées à chaque epoch de checkpoint : (A) cross-entropy seule, (B) CE + Dice, (C) CE + Dice + boundary Kervadec, et (D) CE + boundary Kervadec.

Le résultat principal est un **décalage entre training court et long**. À 10 epochs, la formulation conjointe C mène (78,17 vs 75,91 mIoU, $\Delta = +2,26$ sur B en moyenne), cohérent avec la recette canonique Dice + boundary. À 160 epochs, l'image s'inverse : la variante boundary-only **D atteint la plus haute mIoU moyenne ($81,69 \pm 0,25$) et le meilleur Boundary F1 ($77,32 \pm 0,13$)**, tandis que les variantes Dice mènent sur le Trimap IoU (B $53,82 \pm 0,36$, C $53,87 \pm 0,53$). Sous un test t apparié par seed ($n=3$, corrigé par Holm dans chaque métrique), l'avantage mIoU de D est significatif sur C ($\Delta = +0,46$, $p = 0,007$) mais **pas** sur A ni B ($p = 0,095$, $0,075$) : l'effet est directionnellement cohérent sur les trois seeds, mais $n=3$ manque de puissance pour certifier des écarts $< 0,6$ mIoU. Les deux métriques de contour, en revanche, se séparent nettement le long de l'axe Dice avec une forte significativité : les variantes non-Dice (A, D) mènent le Boundary F1 ($D - B = +0,93$, $A - B = +0,85$; Holm $p \leq 0,011$) tandis que les variantes Dice (B, C) mènent le Trimap IoU ($B - D = +1,57$, $C - D = +1,62$; Holm $p \leq 0,012$). Le terme Dice échange la netteté des contours contre la cohérence régionale ; passé le coude de saturation, il n'aide ni ne pénalise la mIoU globale mais freine la convergence finale sur les grandes classes structurées.

Contributions. (1) Une ablation 2×2 reproductible de loss à

1024×2048 avec le mIoU officiel Cityscapes (estimateur validé bit-pour-bit contre cityscapesscripts), des IC 95 % Student-t et des tests de significativité appariés par seed corrigés par Holm sur trois métriques pour douze runs. (2) Une évidence empirique que les ablations courtes sont trompeuses sur cette tâche — à 10 epochs un pilote choisit C, mais à 160 epochs D dépasse significativement C ($p = 0,007$). (3) Une décomposition par classe montrant que D mène sur les grandes classes structurées (truck +5,29, wall +3,73, bus +2,37 mIoU vs B) tandis que B préserve les classes thin riches en signal (traffic light +2,10, train +1,10, traffic sign +0,86 mIoU vs D). (4) Un **filtre consensus** par composantes connexes (veto entre variantes + vote multi-seed) adapté de BRATS pour retirer les fragments parasites et quantifier l’incertitude inter-seed. (5) Publication ouverte du code, des configs, des métriques par epoch des douze runs, et d’une page web compagnon avec figures interactives.

1. Introduction

La segmentation sémantique de scènes urbaines est canoniquement évaluée sur Cityscapes [Cordts 2016] (19 classes d’évaluation, 2 975 images d’entraînement annotées finement, 500 images de validation). Le sommet du leaderboard publié dépasse confortablement 84 mIoU [Xie 2021 ; Wang 2022], atteint avec des backbones très lourds (ViT-Adapter-L, InternImage-XL), une augmentation massive de données, une inférence multi-échelle et des pseudo-labels tirés du split grossier de 20 000 images. Le présent papier ne vise pas le SOTA ; il vise une question contrôlée :

Ajouter la loss boundary de Kervadec [2019] à une recette CE + Dice solide aide-t-elle sur Cityscapes à pleine résolution — et le Dice reste-t-il utile une fois le terme boundary présent ?

La majorité des travaux antérieurs pré-redimensionnent les inputs à 512×1024 ou 768×1536 pour des raisons de calcul. Avec un GPU Blackwell 96 Go, on peut entraîner à la résolution native 1024×2048 sans crops, ce qui devrait amplifier le rôle de tout composant de loss sensible aux contours.

Ce papier poursuit trois objectifs :

- **Isolation empirique** de la loss boundary de Kervadec dans quatre configurations (A : CE ; B : CE+Dice ; C : CE+Dice+Bnd ; D : CE+Bnd), chacune avec trois seeds et évaluation complète par epoch.

- **Dynamique de convergence** : montrer que l'ordre relatif des recettes de loss change entre epoch 10 et epoch 160, et quantifier ce retournement.
 - **Analyse par classe** disentanglant où Dice aide et où il nuit, au-delà du score mIoU global.
-

2. Travaux connexes

Segmentation sémantique sur Cityscapes. Le benchmark Cityscapes a structuré une décennie de progrès, de FCN [Long 2015] à DeepLab [Chen 2017] et HRNet [Sun 2019] jusqu'aux architectures transformer comme SegFormer [Xie 2021] et Mask2Former [Cheng 2022]. La recette d'entraînement standard à résolutions compétitives utilise la cross-entropy avec deep supervision ; les gagnants récents ajoutent des losses auxiliaires balancées par région (Lovász-Softmax, OHEM) mais font rarement du signal boundary un terme explicite.

Fonctions de loss. La cross-entropy est la baseline universelle pixel-wise. La Dice loss [Milletari 2016] optimise directement le ratio d'overlap régional et constitue le remède de facto au déséquilibre de classes sur images naturelles et médicales. La Focal loss [Lin 2017] re-pondère les pixels difficiles mais reste basée région. Les losses Hausdorff [Karimi 2019] pénalisent la déviation de contour maximale mais nécessitent des approximations différentiables et sont coûteuses en calcul.

Boundary loss [Kervadec 2019]. La loss boundary de Kervadec exprime la divergence de contour comme une intégrale régionale pondérée par la transformée de distance signée (SDT) du masque vérité terrain. Elle est différentiable, ne nécessite qu'une précomputation EDT par image, et peut s'ajouter à n'importe quel pipeline sous la forme $\lambda_b \mathcal{L}_{Bnd}$. Validée à l'origine sur des données médicales fortement déséquilibrées, son interaction avec le Dice sur scènes naturelles reste peu étudiée. On ne fait délibérément **pas** de sweep sur λ_b ici afin de garder l'ablation interprétable ; une extension à poids adaptatif est laissée à de futurs travaux.

Métriques boundary-aware. Le Trimap IoU [Csurka 2013] restreint la mIoU à une bande étroite autour des contours vérité terrain ; le Boundary F1 [Perazzi 2016] calcule précision/rappel des contours prédits dans une tolérance en pixels. On reporte les deux à côté de la mIoU car cette dernière est dominée par les grandes classes (route, bâtiment, végétation) où le signal boundary a peu de levier.

3. Méthodes

3.1 Architecture et entraînement

Backbone. ConvNeXt-V2-Base [Woo 2023] (≈ 88 M paramètres), pré-entraîné sur ImageNet-22K avec l’objectif auto-supervisé FC-MAE puis fine-tuné sur ImageNet-1K (poids `convnextv2_base.fcmae_ft_in22k_in1k_384`). Sorties feature pyramid aux strides 4, 8, 16, 32.

Tête. UPerNet [Xiao 2018] : Feature Pyramid Network plus Pyramid Pooling Module, prédisant 19 logits par pixel à la résolution complète d’entrée via upsampling bilinéaire. Une tête auxiliaire FCN sur les features stride-16 fournit la deep supervision avec un poids de loss de 0,4, comme dans la recette originale.

Entraînement. 160 epochs d’AdamW (lr 6×10^{-5} , weight decay 0,01, betas (0,9, 0,999)) avec polynomial decay (power 1,0). Batch size 2 avec gradient accumulation de 4 (effectif 8). Autocast BF16 (pas de gradient scaler nécessaire sur Blackwell). Les inputs sont utilisés à la résolution native 1024×2048 sans cropping ; l’augmentation est restreinte au flip horizontal, jitter photométrique et blur gaussien. Pas de random scale, pas de Mosaic, pas de Copy-Paste — délibérément simple pour préserver l’interprétabilité de la comparaison de losses. Trois seeds par variante : 42, 123, 456. Checkpoints sauvés toutes les 10 epochs et à epoch 160.

3.2 Nommage des variantes

Variante	Loss	λ_d	λ_b
A	CE	—	—
B	CE + Dice	1,0	—
C	CE + Dice + Boundary	1,0	0,2
D	CE + Boundary	—	0,2

Le poids CE est fixé à 1,0 partout. Les poids Dice et boundary sont pris depuis la recette Cityscapes la plus citée (B) et le défaut Ker-vadec ($\lambda_b = 0, 2$). On n’a délibérément **pas** grid-search les poids : le but est d’isoler l’effet qualitatif de chaque terme, pas de tuner.

3.3 Formulation des losses

Soit Ω le domaine de l’image, $p_c(x) \in [0, 1]$ la probabilité softmax de la classe c au pixel x , $y_c(x) \in \{0, 1\}$ la vérité terrain one-hot, et

$\varphi_c(x) \in \mathbb{R}$ la SDT par classe (négatif à l'intérieur, positif à l'extérieur, normalisée à $[-1, 1]$).

Cross-entropy.

$$\mathcal{L}_{CE} = -\frac{1}{|\Omega|} \sum_{x \in \Omega} \sum_c y_c(x) \log p_c(x).$$

Dice (classe-moyenne, lissé).

$$\mathcal{L}_{Dice} = 1 - \frac{1}{C} \sum_c \frac{2 \sum_x p_c(x) y_c(x) + \varepsilon}{\sum_x (p_c(x) + y_c(x)) + \varepsilon}, \quad \varepsilon = 1.$$

Boundary Kervadec.

$$\mathcal{L}_{Bnd} = \frac{1}{C |\Omega|} \sum_c \sum_{x \in \Omega} \varphi_c(x) p_c(x).$$

Les losses composites sont :

$$\mathcal{L}_B = \mathcal{L}_{CE} + \mathcal{L}_{Dice}, \quad \mathcal{L}_C = \mathcal{L}_{CE} + \mathcal{L}_{Dice} + 0,2 \mathcal{L}_{Bnd}, \quad \mathcal{L}_D = \mathcal{L}_{CE} + 0,2 \mathcal{L}_{Bnd}.$$

3.4 Précomputation des distance maps

La SDT φ_c est calculée offline pour chaque image d'entraînement, une fois par classe, via `scipy.ndimage.distance_transform_edt` sur le masque binaire de classe. Chaque map par classe est clipée à $[-127, 127]$ pixels et stockée comme tenseur `int8` de forme $(19, H, W)$, persistée sur SSD avec `fsync` pour éviter le recalcul. Coût de preprocessing par image : ~ 4 s sur 8 P-cores. Taille par image : 38 MB ($19 \times 1024 \times 2048 \times 1$ octet) ; **cache total pour le train : ~ 113 GB** pour 2 975 images. Le choix d'un tenseur `int8` complet non compressé (pas de narrow-band, pas d'encodage sparse) échange du disque contre le runtime read path le plus simple ; `int8` à résolution pixel-unitaire suffit pour le signal de gradient Kervadec à 1024×2048 .

4. Expériences

4.1 Données

Annotations fines Cityscapes : 2 975 train, 500 val, 1 525 test (labels de test retenus, toutes les métriques rapportées sur val). 19 classes d'évaluation ; 8 classes void exclues comme standard. Résolution native 2048×1024 ; on utilise la résolution complète à l'entraînement et à l'évaluation sans redimensionnement. Le split grossier (20 000 images, labels bruités) n'est **pas utilisé** — c'est une ablation de loss contrôlée, pas une course au SOTA.

4.2 Métriques

- **mIoU** : Intersection-over-Union moyenne sur les 19 classes à partir d'une unique matrice de confusion au niveau du dataset (label void exclu), calculée à pleine résolution. L'estimateur est validé comme bit-identique à la routine officielle cityscapesscripts (tests/test_official_miou.py), de sorte que le mIoU rapporté est la valeur officielle Cityscapes.
- **IoU par classe** : idem, ventilé par classe.
- **Boundary F1** : F1 par classe des contours prédits vs vérité terrain dans une tolérance de 3 pixels, moyenné sur les classes présentes dans chaque image. Les contours sont extraits de masques binaires par classe.
- **Trimap IoU** : mIoU restreinte à une bande de 3 pixels autour de toutes les frontières inter-classes (chaque transition de classe, pas seulement route-vs-reste), mettant l'accent sur l'accuracy de contour.

Toutes les métriques sont rapportées en moyenne sur trois seeds avec intervalle de confiance 95 % via la valeur critique de **Student** ($t_{0,975, df=2} = 4,303 \times SE$; l'approximation normale 1,96 sous-estime l'intervalle d'un facteur $\sim 2,2$ à $n=3$). Les comparaisons par paires utilisent un test t apparié par seed, qui bloque sur le seed partagé et est plus puissant que la comparaison de chevauchement des barres d'IC ; à l'intérieur de chaque métrique, les six p-values par paires sont corrigées par Holm pour les comparaisons multiples (α familial = 0,05).

Note de correction (cette révision). Deux problèmes d'estimateur dans la v0.1.0 ont été trouvés après le premier brouillon du manuscrit et corrigés. (i) Le Boundary F1 et le Trimap IoU étaient calculés en appliquant une morphologie binaire à la carte de labels multi-classes, ce qui traite toute classe non nulle comme avant-plan — seul le contour route-vs-reste était donc mesuré, pas

les frontières inter-classes que les métriques prétendent moyenner. Les deux sont désormais calculés par classe sur masques binaires, et **les douze runs ont été ré-évalués sur le val set** avec l’estimateur corrigé ; les chiffres de §5 sont les chiffres corrigés. Les valeurs absolues de contour bougent substantiellement par rapport à la v0.1.0 (Boundary F1 $\approx 58 \rightarrow \approx 77$, Trimap $\approx 48 \rightarrow \approx 53$) parce que la métrique moyenne désormais sur les 19 classes au lieu de route-vs-reste — et l’ordre qualitatif change aussi, de sorte que les chiffres de contour de la v0.1.0 ne doivent pas être cités. (ii) Les IC 95 % utilisaient 1,96 au lieu du facteur de Student et la significativité s’appuyait sur le chevauchement des barres d’IC ; les intervalles utilisent désormais $t_{0,975,df=2} = 4,303$ et les comparaisons utilisent des tests t appariés par seed corrigés par Holm. La mIoU rapportée est inchangée (elle n’a jamais dépendu du bug de contour) et est calculée par un estimateur **validé bit-pour-bit contre la routine officielle** cityscapesscripts (tests/test_official_miou.py).

4.3 Matériel et runtime

Un seul NVIDIA RTX PRO 6000 Blackwell Max-Q (96 Go GDDR7, sm_120), 64 Go DDR5, Intel i7-14700K. Coût d’entraînement moyen par variante : ~ 28 h pour 160 epochs à batch-2 (623 s/epoch, VRAM peak 32,8 Go). L’évaluation offline des 12×17 checkpoints versionnés a pris ~ 5 h avec 6 workers d’eval parallèles sur le même GPU (CPU-bound sur la boucle de post-process boundary-F1 / trimap).

5. Résultats

5.1 Métriques globales à epoch 160

Moyenne sur 3 seeds avec IC 95 % Student-t, évaluée sur les 500 images Cityscapes val.

Variante	mIoU	Boundary F1	Trimap IoU
A — CE	$81,28 \pm 0,53$	$77,24 \pm 0,16$	$52,17 \pm 0,14$
B — CE+Dice	$81,09 \pm 0,74$	$76,39 \pm 0,24$	$53,82 \pm 0,36$
C — CE+Dice+Bnd	$81,23 \pm 0,21$	$76,50 \pm 0,54$	$53,87 \pm 0,53$
D — CE+Bnd	$81,69 \pm 0,25$	$77,32 \pm 0,13$	$52,25 \pm 0,36$

IC = 95 % Student-t (df = 2). Les trois colonnes sont les estimateurs

corrigés par classe, ré-évalués sur les 500 images du val set ; le mIoU égale la valeur officielle cityscapesscripts (validé bit-pour-bit). Le gras marque la meilleure moyenne par colonne (sur le Trimap, B et C sont statistiquement à égalité — $\Delta = 0,05$, $p = 0,71$ — C est nominalelement le plus haut).

Trois observations :

1. **D a la plus haute mIoU moyenne**, de +0,40 / +0,59 / +0,46 sur A / B / C. Mais la significativité ne suit pas automatiquement à $n=3$. Un test t apparié par seed ne rend significatif que **D > C** ($\Delta = +0,46$, $t = 11,8$, p brut = 0,007, p ajusté par Holm = 0,042 — C a une très faible variance inter-seed) ; **D > A ($p = 0,095$) et D > B ($p = 0,075$) ne sont pas significatifs**, bien que les trois seeds favorisent D dans les deux cas. L'affirmation de la v0.1.0 selon laquelle la borne basse d'IC de D dépasse les bornes hautes des autres reposait sur des intervalles à l'échelle 1,96 (trop serrés) ; avec le facteur t correct, les IC mIoU de A / B / D se chevauchent. L'énoncé honnête : D est la meilleure recette en moyenne et bat significativement la variante conjointe C, mais reste statistiquement indistinguable du CE simple (A) à ce nombre de seeds.
2. **Le Boundary F1 se sépare le long de l'axe Dice**. Les deux variantes sans Dice mènent — D (77,32) et A (77,24) — sur les variantes Dice C (76,50) et B (76,39). $D - B = +0,93$ et $A - B = +0,85$ sont significatifs (p ajusté par Holm = 0,011 et 0,010) ; $D - A = +0,07$ ne l'est pas (les deux meneurs sont à égalité). Le terme Dice adoucit mesurablement les contours prédits. Cette structure était invisible sous l'estimateur route-vs-reste de la v0.1.0, qui plaçait les quatre variantes à moins de 0,2 les unes des autres et conduisait à « aucune affirmation ».
3. **Les variantes Dice gagnent sur le Trimap IoU**, et l'effet est fortement significatif. B (53,82) et C (53,87) mènent les deux variantes non-Dice : $B - D = +1,57$, $C - D = +1,62$, $B - A = +1,65$, $C - A = +1,70$, toutes Holm-significatives ($p \leq 0,012$) ; B et C sont à égalité ($\Delta = 0,05$, $p = 0,71$), tout comme A et D ($\Delta = 0,08$, $p = 0,24$). C'est l'image miroir du Boundary F1 : l'emphase régionale du Dice préserve la cohérence de blob près des contours au prix de la netteté des bords.

5.2 Dynamique de convergence — le retournement 10 vs 160 epochs




Figure 1: Convergence

Figure 1 : mIoU par epoch (moyenne sur 3 seeds ; bande ombrée = IC 95 % Student-t). Le Boundary F1 / Trimap IoU par epoch ne sont pas montrés : seuls les checkpoints d’époch 160 ont été conservés, de sorte que les métriques de contour corrigées par classe n’ont pas pu être recalculées aux epochs intermédiaires — le Tableau 1 donne les valeurs corrigées à epoch 160.

À **epoch 10** la formulation conjointe **C est clairement la meilleure sur le mIoU** (la métrique sur laquelle le classement s’inverse plus tard) :

Métrique	A	B	C	D
mIoU (10 ep)	75,75	75,91	78,17	76,25

(Le Boundary F1 / Trimap par epoch sont omis — voir §4.2 : seul l’époch 160 a été ré-évalué avec l’estimateur corrigé par classe.)

C mène B de **+2,26 mIoU** à epoch 10, un delta qui pousserait toute étude d’ablation courte à recommander la formulation conjointe. Cet

écart précis **n'est pas significatif** individuellement à $n=3$ (p apparié = 0,10), gonflé par un seed à forte variance (par seed $C-B = +1,15 / +1,84 / +3,79$). Le signal robuste et significatif est le **retournement D-vs-C** : D est derrière C à epoch 10 ($-1,92$ mIoU) et le dépasse à epoch 160 ($+0,46$, p apparié = 0,007). À **epoch 50** les quatre variantes convergent dans une bande plus serrée ($\Delta < 1$ mIoU) ; après epoch 100 **D prend la tête et y reste à partir d'epoch 110**. Le retournement est reproductible sur les trois seeds.

C'est l'observation centrale du papier : **une ablation à 10 epochs sur cette tâche choisit un autre vainqueur que le run convergé** — significativement sur l'axe D/C, et directionnellement sur C/B. Le terme Dice fournit une régularisation en début d'entraînement qui accélère la convergence (visible dans la montée de mIoU entre epochs 4 et 10) mais ne se traduit pas en avantage long-training sur la métrique globale. Le terme boundary, lui, prend plus d'epochs pour s'intégrer au signal de gradient — le champ SDT fournit un gradient distribué faible qui a besoin de plus de steps pour déplacer la frontière de décision — mais finit par produire une mIoU et un Boundary F1 plus élevés une fois convergé.

5.3 Décomposition par classe à epoch 160




Figure 2: IoU par classe

Figure 2 : IoU par classe à epoch 160, triées par $\Delta(D - A)$. Les barres sont la moyenne sur 3 seeds.

Le delta mIoU global cache une histoire fortement classe-dépendante. En prenant les sept classes avec le plus gros mouvement entre B et D :

Classe	A	B	C	D	$\Delta(D-A)$	$\Delta(D-B)$	$\Delta(C-B)$
wall	57,76	57,92	57,17	61,64	+3,88	+3,73	-0,75
truck	85,86	80,24	84,22	85,54	-0,32	+5,29	+3,98
bus	90,89	89,75	89,77	92,12	+1,23	+2,37	+0,03
terrain	66,91	66,10	66,42	67,61	+0,70	+1,51	+0,32
traffic light	74,60	76,85	77,01	74,76	+0,16	-2,10	+0,15
traffic sign	82,73	83,52	83,60	82,65	-0,08	-0,86	+0,08
train	82,76	83,74	81,73	82,63	-0,13	-1,10	-2,00

Deux patterns émergent :

- **D domine les grandes classes étendues structurées** (truck +5,29 vs B, wall +3,73, bus +2,37). Ces classes ont des intérieurs longs et uniformes et des contours bien définis — le champ de gradient SDT est signé de manière cohérente sur toute la région, et le terme Kervadec aligne fidèlement la prédiction.
- **B (et dans une moindre mesure C) préserve les classes thin riches en signal** (traffic light, traffic sign, train). Ces classes ont des footprints petits ou fragmentés ; le terme Dice les ancre contre la dérive class-imbalance de la CE, tandis que la loss boundary seule est plus bruitée sur un poteau de 4 pixels de large que sur un bus de 200 pixels.

Cette complémentarité n'est **pas** capturée par la mIoU globale, où les grandes classes (road, building, vegetation, sky) dominent. Les quatre grandes classes étendues qui répondent à D contribuent à ~70 % du swing de mIoU entre D et B à epoch 160 ; les classes thin où B gagne sont individuellement larges en delta mais petites en pixel count.

5.4 Variance inter-seeds

Les IC 95 % Student-t induits par les seeds varient largement entre métriques et variantes. Parmi les métriques globales, C a l'IC mIoU le plus serré ($\pm 0,21$) et D le Boundary F1 le plus serré ($\pm 0,13$) ; les IC de contour les plus larges sont ceux de C ($\pm 0,54$ Boundary F1, $\pm 0,53$ Trimap). Au niveau classe, **truck** sous la variante B est la plus volatile — écart-type inter-seeds de 4,40 points IoU (vs 2,55 std pour D, 0,68 pour C, 0,78 pour A). Avec truck apparaissant dans seulement **80 des 500 images val**, l'emphasis régionale du Dice amplifie les fluctuations sur les classes à faible support.

5.5 Filtrage consensus — fusionner variantes et seeds complémentaires

La décomposition par classe (§5.3) montre que D et B sont complémentaires : D mène sur les grandes classes structurées, B sur les classes thin riches en signal. L’analyse inter-seed (§5.4) révèle un second axe de marge : une variance qu’un seed unique ne peut moyenner. Les deux invitent à une étape de consensus. On adapte le **filtre consensus** par composantes connexes (CC) de nos travaux BRATS, où une segmentation « généraliste » est vetoée par une « spécialiste » : par classe, toute composante connexe du généraliste sans recouvrement de même classe dans le veto est retirée, ce qui élague les fragments hallucinés et améliore les métriques de contour sans coût sur l’overlap régional.

Cityscapes impose quatre écarts à la formulation BRATS — c’est une adaptation, pas un portage :

- **Connexité 8 en 2D** au lieu de 26 en 3D.
- **19 classes plates** sans hiérarchie WT/TC/ET emboîtée — le veto opère sur 19 masques de classe indépendants.
- **Pas de classe de fond.** En BRATS une composante retirée passe au fond (0) ; chaque pixel Cityscapes porte une classe, donc une composante retirée est **réassignée au label du veto** (mettre 0 voudrait dire « route »). La réassignation est bien définie justement parce que la composante a zéro recouvrement avec le masque même-classe du veto.
- **Protection des structures fines.** Pole, traffic light, traffic sign et fence sont des composantes légitimement petites et fragmentées qu’un veto naïf effacerait — le mode de défaillance spécifique à Cityscapes (BRATS rapportait 38,7 % de cas dégradés par un veto trop agressif ; ici le risque se concentre sur les classes fines). Elles sont exemptées par défaut, et un plafond `max_drop_size` restreint la suppression aux vrais fragments.

Deux modes sont fournis : **(a) veto entre variantes** — D (généraliste) vetoé par B (spécialiste), ciblant les gains grandes-classes de D tout en laissant B vetoer les fragments parasites ; et **(b) vote majoritaire multi-seed** avec une **carte d’accord** par pixel (fraction des trois seeds en accord), un ensemble naturel sur Cityscapes qui attaque directement la variance inter-seed de §5.4 et fournit un signal d’incertitude gratuit pour l’analyse d’erreurs. On rapporte aussi un **compte de fragments** (composantes connexes par classe) comme proxy de cohérence spatiale indépendant de la mIoU ; le filtre ne peut que le baisser.

Statut. Le filtre, la métrique de compte de fragments et une suite de tests unitaires synthétiques (19/19) sont publiés avec le

code (src/postprocessing/consensus.py). Les chiffres quantitatifs sur le val set — Δ mIoU, Δ compte de fragments, corrélation carte-d'accord/erreurs — nécessitent de relancer l'inférence pour exporter les prédictions par image et sont **reportés à la version finale** ; ils n'étaient pas disponibles à cette révision car les checkpoints entraînés résident sur un stockage séparé. On ne fait donc **aucune affirmation chiffrée** sur le filtre consensus ici ; il est présenté comme une méthode reproductible à l'implémentation vérifiée.

6. Discussion

6.1 Pourquoi D dépasse-t-il C à pleine durée d'entraînement ?

On propose deux explications compatibles.

Interférence de gradient entre Dice et Boundary. Dice et Kervadec déplacent tous deux la frontière de décision, mais avec des critères différents : Dice maximise un ratio d'overlap régional (un scalaire par classe, intégré sur toute l'image), tandis que Kervadec minimise la masse de probabilité pondérée par la SDT à chaque pixel. Les deux gradients s'accordent près du contour (poussant les pixels mal classés dans le même sens) mais divergent à l'intérieur des régions, où le Dice continue d'agir (parce qu'augmenter p_c dans un vrai positif fait croître le numérateur plus vite que le dénominateur) tandis que Kervadec est approximativement neutre (l'amplitude SDT est bornée). Tôt, le signal Dice domine et accélère la convergence ; tard, quand la plupart des régions bulk sont déjà correctes, le signal Dice résiduel devient un régularisateur soft qui empêche la loss boundary de faire les derniers ajustements. La variante D, libérée de la contrainte Dice, peut pleinement exploiter le gradient aligné contour de Kervadec.

Saturation du déséquilibre de classes. La valeur publiée principale du Dice est la gestion du déséquilibre de classes. À epoch 50-60, les IoU par classe ont déjà plateausé pour les classes rares — elles atteignent un équilibre par classe en dessous duquel la loss boundary ne les blesse pas davantage. Après ce point, le Dice continue de pénaliser le sous-confiance résiduel sur les intérieurs des classes rares au prix de la fidélité de contour des classes dominantes. D, sans Dice, laisse les classes dominantes récupérer ces derniers pixels.

6.2 Boundary F1 vs Trimap IoU — le compromis Dice

Les deux métriques de contour se séparent le long de l’axe Dice, et les deux séparations sont significatives (§5.1). Le Trimap IoU est une IoU restreinte aux pixels à 3 px d’un contour vérité terrain : il pénalise les faux positifs hors de la vraie région (expansion de contour) et les faux négatifs dedans (rétraction). Le Dice optimise un ratio d’overlap régional, qui tire la prédiction vers le bulk de la région — ce qui garde la bande proche du contour cohérente (Trimap IoU plus élevé pour B et C) mais arrondit les détails fins de contour (Boundary F1 plus bas). Les deux variantes sans Dice (A = CE, D = CE + boundary) gardent des bords plus nets et mènent donc le Boundary F1 — D le plus haut, le gradient SDT alignant explicitement les contours — au prix de $\approx 1,6$ points de Trimap. Les métriques corrigées par classe rendent ce compromis à la fois visible et significatif ; l’estimateur route-vs-reste de la v0.1.0 ramassait le Boundary F1 à moins de 0,2 sur les quatre variantes et le cachait.

6.3 Prises actionnables

- **Pour un modèle Cityscapes déployé** : D (CE + Kervadec, $\lambda_b = 0, 2$) est le défaut pragmatique. C’est la plus simple des quatre (pas de plumbing Dice, pas d’hyperparamètre), a la plus haute mIoU moyenne — significativement au-dessus de la variante conjointe C, et à égalité avec le CE simple (A) à ce nombre de seeds — et se comporte de manière prévisible sur les grandes classes structurées. Là où la cohérence régionale près des contours compte plus que la netteté des bords, une variante Dice (B ou C) est préférable — B et C mènent le Trimap IoU de $\approx +1,6$ (significatif) — et B protège en plus les classes thin riches en signal (traffic light, traffic sign).
- **Pour un pipeline multi-task qui a déjà Dice pour d’autres raisons** (ex : loss partagée entre la segmentation et une tête auxiliaire class-imbalanced) : utiliser C. Le sacrifice de +0,5 mIoU vs D est petit par rapport au coût d’ingénierie du découplage du Dice.
- **Ne pas faire confiance aux ablations à 10 epochs** pour comparer des variantes Dice sur Cityscapes. Le retournement d’ordre early-vs-late qu’on mesure ($+2,26 \rightarrow -0,46$ dans le gap C-B, un swing de 2,7 points) suggère qu’une décision production doit être prise sur au moins 80-100 epochs d’entraînement.

6.4 Limitations

- **Un seul λ_b .** On a fixé $\lambda_b = 0, 2$. Un sweep sur $\{0,05, 0,1, 0,2, 0,5\}$ permettrait de dire si l'avantage de D est robuste ou spécifique à ce poids. Les surfaces d'interaction à deux losses sont notoirement non-monotones.
- **Un seul backbone.** Les quatre variantes partagent ConvNeXt-V2-Base + UPerNet. Les têtes SegFormer / Mask2Former pourraient ne pas montrer le même retournement, notamment parce que Mask2Former re-pondère en interne les pixels de contour via son mask-attention.
- **Budget d'entraînement sous la référence MMSegmentation.** 160 epochs à batch effectif 8 correspondent à environ 60 k steps SGD — environ 37 % du budget standard de 160 k itérations utilisé par MMSegmentation pour Cityscapes à batch 16. Le retournement est observé dans ce budget ; un training plus long pourrait élargir davantage l'avantage de D ou modifier l'image par classe.
- **Pas de TTA, pas d'inférence multi-échelle.** Le test-time augmentation gagne typiquement 1-2 mIoU mais obscurcit les comparaisons de losses ; on rapporte des nombres single-scale partout.
- **Les hypothèses de §6.1 ne sont pas directement mesurées.** L'interférence de gradient entre Dice et Kervadec est proposée comme mécanisme derrière le lead tardif de D, mais les normes de gradient par layer/epoch ne sont pas extraites dans ce papier. Une étude ciblée de trajectoire de gradient est laissée à de futurs travaux.
- **Cityscapes seulement.** Si le phénomène de retournement généralise à ADE20K, COCO-Stuff, Mapillary, ou des datasets de conduite non structurés (BDD, IDD) est une question ouverte.
- **Trajectoires de contour par epoch non ré-évaluées.** Les Boundary F1 / Trimap corrigés par classe ont été recalculés à epoch 160 pour les douze runs (Tableau 1) ; les checkpoints aux epochs intermédiaires n'ont pas été conservés, de sorte que la figure de convergence (§5.2) ne montre que la mIoU.
- **Faible puissance statistique ($n = 3$).** Les écarts $< 0,6$ mIoU (D vs A, D vs B) sont directionnellement cohérents mais non significatifs à trois seeds. Un re-run à cinq seeds est le moyen le moins cher de les trancher. Les résultats significatifs (D > C sur mIoU ; les variantes Dice B, C > A, D sur Trimap ; A, D > B sur Boundary F1 ; le retournement D/C) ne sont pas affectés.
- **Filtre consensus non encore chiffré.** Le filtre de §5.5 a une implémentation vérifiée et des tests unitaires mais aucun résultat sur le val set dans cette révision (checkpoints hors-machine).

6.5 Implications pour le déploiement véhicule autonome

Les trois métriques se projettent sur des consommateurs aval distincts dans un stack de perception VA. Le Trimap IoU mesure la cohérence intra-région près des contours — la métrique qui compte quand un planner lit le masque de segmentation directement comme grille d’occupation ou estimateur de free-space. Le Boundary F1 mesure la localisation précise du contour — la métrique qui compte quand on extrait des polygones de bord de voie, de trottoir ou d’objet pour estimation de distance ou planification de trajectoire. La décomposition par classe ajoute un second axe : la loss qui gagne sur la mIoU globale n’est pas nécessairement celle qui gagne sur la classe spécifique que le downstream regarde le plus.

Cela transforme le résultat à 4 variantes en guide module par module plutôt qu’en recommandation unique :

- **Heads « drivable area » / « free-space »** qui alimentent une grille d’occupation : une variante Dice (B ou C), dont l’avantage $\approx +1,6$ Trimap IoU sur les variantes non-Dice préserve la cohérence du blob et évite l’overshoot sur la classe voisine.
- **Heads « lane » / « curb detection »** qui émettent des polygones : D (CE + Boundary), dont les contours plus nets se traduisent par une meilleure estimation latérale. Avec la caméra Cityscapes (focale $f_x \approx 2262$ px), une erreur d’1 pixel correspond à $\sim 1,3$ cm d’offset latéral réel à 30 m, $\sim 4,4$ cm à 100 m, $\sim 8,8$ cm à 200 m — la précision sub-pixel du contour devient critique en longue portée.
- **Classifieurs traffic light / traffic sign** qui reçoivent un crop de segmentation : B, qui mène D de $+2,10$ IoU sur traffic light et $+0,86$ sur traffic sign — la région plus propre maintient le classifieur d’état sur les bons pixels.
- **Détecteurs d’objets rigides étendus** (truck, bus, wall) pour collision et lane-keeping : D, qui mène B de $+5,29$ sur truck, $+2,37$ sur bus, $+3,73$ sur wall.
- **Piéton, cycliste et rider** : scores essentiellement plats sur A-D dans nos expériences. Le choix de loss ne pèse pas sur ces classes collision-critical. Des techniques orthogonales (focal loss, copy-paste augmentation, oversampling) sont nécessaires.

Pour un pipeline d’entraînement multi-head, la conception actionnable consiste à choisir une loss par head : Dice (ou CE+Dice) sur les heads qui produisent des masques type occupancy, et CE+Boundary sur les heads qui produisent des polygones ou des contours nets. La variante conjointe C (CE+Dice+Boundary) reste le compromis single-loss sûr pour les modèles single-head — jamais le pire, jamais le meilleur, utile quand des contraintes d’ingénierie

excluent la conception loss-par-head.

Le résultat le plus transférable pour une équipe ML VA est méthodologique. Un benchmark de loss à 10 epochs sur Cityscapes décale le gap C–B en mIoU de 2,7 points par rapport à la réponse convergée — suffisant pour inverser une décision production. Les choix de recette de loss pour un module de perception VA doivent être faits sur au moins 80–100 epochs d’entraînement, avec la métrique alignée sur le downstream consommateur plutôt qu’une poursuite générique de mIoU.

7. Conclusion

On fournit une ablation 2×2 reproductible de l’espace de design des losses CE / Dice / boundary Kervadec pour la segmentation sémantique pleine résolution sur Cityscapes. À 160 epochs avec trois seeds par variante, la variante boundary-only **D (CE + Kervadec)** atteint la plus haute mIoU moyenne ($81,69 \pm 0,25$) et le meilleur Boundary F1 ($77,32 \pm 0,13$) ; sous un test apparié par seed elle dépasse significativement la variante conjointe C ($p = 0,007$) — la formulation qu’un pilote à 10 epochs aurait choisie — tout en restant statistiquement à égalité avec le CE simple (A) à ce nombre de seeds. Les variantes Dice (B, C) gardent une avance significative sur le Trimap IoU ($\approx +1,6$ sur A et D), reflétant leur meilleure cohérence intra-région près des contours — l’image miroir de l’ordre du Boundary F1.

La trouvaille la plus actionnable est méthodologique : **les ablations à epochs courts sont systématiquement trompeuses sur cette tâche**. Une étude comparant des recettes de loss pour Cityscapes à ≤ 20 epochs inverse le ranking qui tient à 160 epochs. On espère que ce travail découragera les conclusions hâtives sur le choix de loss dans de futurs papiers Cityscapes et fournira une baseline contre laquelle calibrer les sweeps λ_b et les variantes d’architecture.

Tout le code, les configs, les métriques par epoch des douze runs, les distance maps précomputées et une page web interactive sont publiés sur github.com/guillaume-cassez/city-scape. Une landing page avec le paper et l’embed du viewer vit sur guillaume-cassez.fr/voiture-autonome/cityscapes/boundary-loss-kervadec/.

Annexe A — Runtime et reproductibilité

Étape	Matériel	Durée	Sortie
Précomputation SDT (one-shot)	8 P-cores	20 min	data/cityscapes_sdt/ (~113 GB, int8)
Training 160 ep, 1 seed	1 × RTX PRO 6000 96 GB Blackwell	28 h	checkpoints/<variant>_seed<s>/
Évaluation 1 checkpoint	1 × RTX PRO 6000	7 min	.results.json à côté du .pth
Batch eval 12 × 17 ckpts	6 workers parallèles 1 GPU	5 h	204 × .results.json
Agrégation + figures	1 P-core	5 s	papers/paper2/figures/

Wall-clock total de la raw data aux figures : ~5 jours de GPU time, principalement training (12 × 28 h ≈ 14 jours sérialisés, mais les seeds ont été lancés séquentiellement par variante et les variantes se sont chevauchées en pipeline).

Seeds de reproductibilité. 42, 123, 456 sont set globalement via `set_seed` (PyTorch, NumPy, Python random, CUDA). cuDNN benchmark est laissé **on** pour un speed-up training de ~10 % ; cela exclut la reproductibilité bit-exact mais c’est une pratique standard pour le training à l’échelle Cityscapes. Les reruns bit-exact sur le même matériel ne sont pas mesurés dans ce papier ; les IC 95 % rapportés ailleurs sont calculés sur les trois seeds indépendants (42, 123, 456) et constituent la statement de reproductibilité opérationnelle.

Annexe B — Meilleures et pires deltas par classe

Top 5 classes où D améliore sur B à epoch 160 :

Classe	B IoU	D IoU	Δ
truck	80,24 ± 4,39	85,54 ± 2,55	+5,29
wall	57,92 ± 1,59	61,64 ± 2,06	+3,73
bus	89,75 ± 2,03	92,12 ± 0,55	+2,37
terrain	66,10 ± 0,64	67,61 ± 0,46	+1,51
fence	66,07 ± 1,27	67,02 ± 0,35	+0,95

Bottom 5 classes où D régresse vs B à epoch 160 :

Classe	B IoU	D IoU	Δ
traffic light	$76,85 \pm 0,14$	$74,76 \pm 0,35$	$-2,10$
train	$83,74 \pm 1,54$	$82,63 \pm 1,10$	$-1,10$
traffic sign	$83,52 \pm 0,16$	$82,65 \pm 0,36$	$-0,86$
bicycle	$79,81 \pm 0,06$	$79,63 \pm 0,20$	$-0,18$
rider	$68,49 \pm 0,95$	$68,34 \pm 0,45$	$-0,15$

Références

- Chen et al. (2017). Rethinking atrous convolution for semantic image segmentation. arXiv:1706.05587.
- Cheng et al. (2022). Masked-attention mask transformer for universal image segmentation. CVPR.
- Cordts et al. (2016). The Cityscapes dataset for semantic urban scene understanding. CVPR.
- Csurka et al. (2013). What is a good evaluation measure for semantic segmentation ? BMVC.
- Karimi & Salcudean (2019). Reducing the Hausdorff distance in medical image segmentation. IEEE TMI 39 (2).
- Kervadec et al. (2019). Boundary loss for highly unbalanced segmentation. MIDL. arXiv:1812.07032.
- Lin et al. (2017). Focal loss for dense object detection. ICCV.
- Long et al. (2015). Fully convolutional networks for semantic segmentation. CVPR.
- Milletari et al. (2016). V-Net: fully convolutional neural networks for volumetric medical image segmentation. 3DV.
- Perazzi et al. (2016). A benchmark dataset and evaluation methodology for video object segmentation. CVPR.
- Sun et al. (2019). High-resolution representations for labeling pixels and regions. arXiv:1904.04514.
- Wang et al. (2022). InternImage: exploring large-scale vision foundation models with deformable convolutions. arXiv:2211.05778.
- Woo et al. (2023). ConvNeXt V2: co-designing and scaling ConvNets with masked autoencoders. CVPR. arXiv:2301.00808.
- Xiao et al. (2018). Unified perceptual parsing for scene understanding. ECCV. arXiv:1807.10221.
- Xie et al. (2021). SegFormer: simple and efficient design for semantic segmentation with transformers. NeurIPS.

Manuscrit — 2026-06-02. Code source, configs, métriques par epoch, script de génération des figures et page web interactive : github.com/guillaume-cassez/city-scape. Auteur : Guillaume Cassez, chercheur indépendant, guillaume-cassez.fr — actuellement à la recherche d'opportunités d'ingénieur ML / vision par ordinateur.